

Arbres & Méthodes d'agrégation

Septembre 2026

Cédric Dangeard

cedric.dangeard@orange.com



Business

Objectifs

- Appréhender la data science en entreprise
- Installer et configurer son environnement de travail
- Visualiser et nettoyer les données
- Comprendre les algorithmes des arbres et les méthodes d'agrégation
- Utiliser Scikit-learn et les librairies R équivalentes
- Réaliser un projet de data science et le restituer


Fonctionnement du cours

- Cours théoriques
- Travaux pratiques (Python & R)
- QCM d'évaluation
- Projet de data science en groupe

Cours 1 : Au programme

- La data science en ESN
- Les étapes d'un projet de Machine Learning
- TP : Installation et prise en main
- La collecte de données
- Le nettoyage des données
- TP : découverte et nettoyage d'un dataset

CATALOGUE DE SERVICES DATA SCIENCE & IA



QUELLES DIFFÉRENCES ENTRE LES PROFILS ?



Data Analyst

Technique

Métier

Statistique

Optimisation

Analytique



Data Engineer

Technique

Métier

Statistique

Optimisation

Analytique



Data Scientist

Technique

Métier

Statistique

Optimisation

Analytique



ML Engineer

Technique

Métier

Statistique

Optimisation

Analytique

QUELLES DIFFÉRENCES ENTRE LES PROFILS ?



Data Analyst

Technique ★★

Métier ★★★★★

Statistique ★★

Optimisation ★

Analytique ★★★★★



Data Engineer

Technique ★★★★★

Métier ★

Statistique ★★

Optimisation ★★★★★

Analytique ★★



Data Scientist

Technique ★

Métier ★★★★★

Statistique ★★★★★

Optimisation ★★★

Analytique ★★



ML Engineer

Technique ★★★★★

Métier ★

Statistique ★★★★★

Optimisation ★★


Analytique ★

ÉTAPES D'UN PROJET ML

Quelles sont les étapes d'un projet de Machine Learning ?

- ?

ÉTAPES D'UN PROJET ML




Checklist de cadrage

Avant de lancer le développement, valider :

- Objectif métier clair (KPI, impact, décision associée)
- Définition de la cible (ce que l'on veut prédire)
- Données disponibles et droits d'usage validés
- Critères de succès (métriques et seuils)
- Contraintes de mise en production (coût, délai, explicabilité)

Exemple MLOps



Mettre en place son environnement

De quoi a-t-on besoin ?

De quoi parle-t-on ?

- Python
- IPython
- ipykernel
- Jupyter Notebooks
- Spyder
- Google Colab
- Anaconda

Python


- Langage de programmation
- Créé en 1991 par Guido van Rossum
- Langage interprété
- Langage multi-paradigme

Que fait Jupyter Server ?

- Permet d'exécuter du code dans un navigateur web
- Permet d'éditer des notebooks
- Communique avec un noyau (kernel, ex : ipykernel pour Python)
- Communique avec le client (interface web)

Pour aller plus loin : [article](#)

Jupyter Server



IDE : Integrated Development Environment

- Environnement de développement intégré
- Permet d'éditer, exécuter et déboguer du code
- Exemples : PyCharm, VS Code, Spyder
- Permet d'installer des extensions

VS Code

- Gratuit et Open Source
- Multi-langages
- Projet Microsoft
- IDE le plus utilisé
- Nombreuses extensions

Pourquoi un environnement virtuel ?

Pourquoi en créer un pour chaque projet ?

- Permet d'isoler les dépendances d'un projet
- Permet d'installer plusieurs versions d'une même bibliothèque
- Permet de partager les dépendances d'un projet
- C'est comme ça qu'on travaille en entreprise

Outils : [virtualenv](#), [venv](#), [pipenv](#), [conda](#)

Créer son environnement

- [venv](#) est la bibliothèque standard de Python pour créer des environnements virtuels, depuis Python 3.3.
- Il existe d'autres outils comme [virtualenv](#) ou [pipenv](#).

```
# Créer un environnement (un dossier monProjetEnv qui contiendra l'environnement)  
python -m venv monProjetEnv  
# Activer l'environnement (sur Windows)  
.\monProjetEnv\Scripts\activate  
# Activer l'environnement (sur MacOS/Linux)  
source monProjetEnv/bin/activate  
# Désactiver l'environnement  
deactivate
```

Installer les bibliothèques

Vérifier que l'environnement est activé (`monProjetEnv`) avant d'installer les bibliothèques.

```
pip install numpy pandas plotly seaborn scikit-learn
```

ou

```
pip install -r requirements.txt
```

uv

Outil moderne pour gérer les environnements virtuels et les dépendances en Python.

```
# Installer uv  
pip install uv  
# Vérifier l'installation  
uv --version  
# Initialiser un projet  
uv init  
# Ajouter des bibliothèques  
uv add numpy pandas plotly seaborn scikit-learn
```


uv

```
# Ajouter des bibliothèques  
uv add numpy pandas plotly seaborn scikit-learn ipykernel jupyter  
# Lancer un serveur Jupyter  
uv run --with jupyter jupyter lab  
# Supprimer une bibliothèque  
uv remove numpy  
# Synchroniser l'environnement avec le fichier uv.lock  
uv sync
```

TP

TP


ÉTAPES D'UN PROJET ML



Collecte


- S'assurer que le projet est réalisable
 - Données disponibles
 - Données suffisantes
 - Données de qualité
- S'assurer de disposer des ressources nécessaires
 - Matériel
 - Délais
- S'assurer de la conformité RGPD du projet

Avec quelles données ?



Avec quelles sources de données ?

Sources de données




Big Data (5V)

- Volume : Quantité de données
- Vélocité : Vitesse de génération des données
- Variété : Diversité des types de données
- Véracité : Fiabilité des données
- Valeur : Utilité des données

CAP theorem

AP :
Rapidité,
toujours accessible,
mais données
pas forcément à jour
ex : Cassandra,
dynamoDB...

CP:
Données correctes,
mais avec latence
ex : MongoDB,
HBase, Redis...



NoSQL

- Bases de données non relationnelles
- Types
 - Clé-valeur (Redis, DynamoDB)
 - Document (MongoDB, CouchDB)
 - Famille de colonnes (Cassandra, HBase)
 - Graphe (Neo4j)

Formats de fichiers orientés colonne

Dans les fichiers orientés lignes (comme CSV), toutes les données d'une même entrée sont stockées ensemble, et donc à la suite sur le disque.

Avantages :

- Facile à lire et écrire
- Bon pour les transactions

Inconvénients :

- Mauvais pour les analyses
- Mauvais pour la compression

Pourquoi les fichiers orientés colonnes ?

Dans les fichiers orientés colonnes, les données d'une même colonne sont stockées ensemble, et donc à la suite sur le disque.

Avantages :

- Performance des requêtes
- Meilleure efficacité de stockage (compression)

Inconvénients :

- Plus complexe à lire et écrire
- Mauvais pour les transactions

Exemple de fichier orienté colonne

1. Apache [Parquet](#)

Le format de fichier colonne le plus utilisé aujourd'hui (Apache Spark, AWS Athena, Google BigQuery, ...)

2. Apache [ORC](#)

Historiquement utilisé avec Apache Hive. Optimisé pour les lectures analytiques et la compression.

3. Apache [Arrow](#)

Un format en mémoire pour le traitement analytique. Utilisé par Pandas, Spark, Dask, ...

RGPD

PASSER À L'ACTION


en 4 étapes

1



Constituez un registre
de vos traitements de données

2




Faites le tri
dans vos données

3



Respectez les droits
des personnes

4



Sécurisez
vos données

Exploration : objectifs

1. Comprendre les données
2. Vérifier l'intégrité et la cohérence des données
 - Valeurs manquantes
 - Doublons
 - Valeurs aberrantes
 - Biais
3. Création d'indicateurs
4. Visualiser

Nettoyage des données

Quels problèmes peut-on rencontrer ?

	Nom	Sexe	Ville	Code Postal	latitude	longitude	Age	Taille	Salaire	Client	Num fidélité	Code Concurrent
0	Paul	M	Paris	75000	48.8566	2.35222	18	1.8	1500	True	1235	
1	Pierre	M	Nante	44000	47.2184	-1.55362	25	1.75	20000	False		A
2	Jacques	M	Lyon	69000	45.764	4.83566	32	170	2500	True	1237	
3	Julie	F	Paris	75000	48.8566	2.35222	45	1.65	nan	False		
4	Anne	F	Nantes	44000	47.2184	-1.55362	18	1.8	1500	True	1238	B
5	Marie	F	Lyon	69000	45.764	4.83566	25	1.75	2030	False		
6	Andr%e	F	Paris	75000	48.8566	2.35222	322	1.7	2500	True		
7	Fassou	M	Nantes	44000	47.2184	-1.55362	45	1.65	3000	False		
8	James	M	Lyon	69000	45.764	4.83566	18	1.8	1500	True	1240	
9	Bob	M	Paris	75000	48.8566	2.35222	25	1.75	2000	False		

Quelles solutions ?

Nettoyage des données

- Variables corrélées
- Variables non pertinentes
- Valeurs manquantes
- Doublons
- Valeurs aberrantes
- Données déséquilibrées
- Biais
- Création de nouvelles variables

Pièges fréquents avant modélisation

- Fuite de données (utiliser des variables indisponibles en production)
- Mélange train/test avant préparation
- Métrique inadaptée au problème (ex: accuracy seule sur classes déséquilibrées)
- Variables mal typées (catégorielle traitée comme continue)
- Valeurs extrêmes non analysées (erreur de saisie vs signal métier)

Données manquantes

Que faire des données manquantes ?


Données manquantes

- Supprimer les lignes/colonnes
- Imputer avec la moyenne/médiane/modale
- Imputer avec un modèle prédictif (KNN, régression, ...)
- Marqueur de données manquantes

Pour aller plus loin : [cours F. Husson](#)

RETOUR AU TP

Des Questions?



Bibliographie

- [ipykernel](#)
- [Jupyter](#)
- [venv](#)
- [virtualenv](#)
- [pipenv](#)
- [uv](#)
- [Scikit-learn](#)
- [CAP theorem](#)